

EcoSage

LLM-Powered Chatbot for Sustainable Policy



Publishers:

- Nima Agha Ghafar Hamedani
- Jort Akershoek
- Vince Ammerlaan
- Tommi Lander

Client:

- Matis Mourey (De Haagse Hogeschool)

Date: 15-6-2025

EcoSage.....	1
LLM-Powered Chatbot for Sustainable Policy.....	1
Inleiding.....	3
1.1 Probleemdefinitie.....	3
1.2 Doel van het onderzoek.....	3
1.3 Onderzoeksvraag en deelvragen.....	4
Hoofdvraag.....	4
Deelvragen.....	4
1.4 Relevantie en context.....	5
1.5 Aanpak en methoden.....	5
Literatuuronderzoek.....	7
2.1 Inleiding van het literatuuronderzoek.....	7
2.2 Energietransities en beleid in Europa.....	7
2.3 Toepassing van AI en LLM in beleid.....	9
2.4 Stakeholdersanalyse.....	11
Methode.....	13
3.1 Dataverzameling en selectie van documenten.....	13
3.2 Exploratory Data Analysis (EDA).....	13
3.3 Data opschoning en preprocessing.....	15
3.4 Architectuur RAG + LLM.....	16
3.5 Prototype front-end.....	18
Resultaten.....	22
4.1 Koppelen Frontend en Backend.....	22
4.2 Metrics.....	24
4.3 Conclusie.....	26
Discussie.....	27
5.1 Reflectie op bepaalde keuzes en gemaakte afwegingen.....	27
5.2 Beperkingen van het onderzoek.....	30
5.3 Vergelijking met bestaande literatuur.....	30
5.4 Juridische en ethische implicaties.....	31
Conclusie.....	33
Aanbevelingen.....	34
Literatuurlijst.....	36

Inleiding

1.1 Probleemdefinitie

Uit de bron van Scribbr (Benders, 2024) blijkt dat een goede probleemstelling aan de volgende drie voorwaarden moet voldoen: (1) het probleem wordt in de juiste context geplaatst, (2) de relevantie voor de doelgroep wordt duidelijk gemaakt, en (3) de probleemstelling aanstuurt op een helder onderzoeksdoel. Hieruit hebben wij deze probleemdefinitie zo gedefinieerd

De energietransitie vereist dat burgers begrijpen welke beleidsmaatregelen er zijn, welke stappen zij kunnen nemen en welke gevolgen dit voor hen heeft. Beleidsdocumenten worden echter vaak opgesteld in complexe, juridische en technische taal. Hierdoor ontstaat een kennisbarrière: burgers kunnen de kernboodschappen niet snel doorgronden en haken af. Dit leidt tot beperkte betrokkenheid bij duurzaamheidsinitiatieven en vermindert de effectiviteit van overheidsbeleid.

1.2 Doel van het onderzoek

Ons onderzoek is gebaseerd op een opdracht van de Haagse Hogeschool (The Hague University of Applied Sciences (THUAS) et al., 2022). Hierin staan achtergrondinformatie en het doel van de opdracht. Hieruit kwam het volgende:

Het doel van dit onderzoek is het ontwerpen, ontwikkelen en evalueren van een prototype van een Large Language Model (LLM)-gebaseerde tool die burgers helpt om complexe energiebeleidsdocumenten te begrijpen. De tool moet in staat zijn om beleidsinformatie op een betrouwbare, toegankelijke en begrijpelijke manier te presenteren, zodat burgers beter geïnformeerde beslissingen kunnen nemen en actiever kunnen deelnemen aan de energietransitie. Het onderzoek richt zich op het toepassen van technieken zoals Retrieval-Augmented Generation (RAG) om relevante informatie op te halen en te herformuleren in begrijpelijke taal, met behoud van de inhoudelijke juistheid.

1.3 Onderzoeksvraag en deelvragen

Hoofdvraag

Uit de bron van Scribbr (Scharwächter, 16 januari 2023) blijkt hoe je een hoofdvraag moet maken: hierin staat dat een hoofdvraag onderzoekbaar, haalbaar, origineel, complex, relevant, specifiek en gefocust op één probleem dient te zijn en dit heeft ons tot de volgende hoofdvraag geleid:

Hoe kunnen we een LLM-gebaseerde tool ontwikkelen die informatie van beleidsdocumenten over de energietransitie genereert tot betrouwbare informatie voor burgers?

Deelvragen

Ook uit de bron van Scribbr (Scharwächter, 16 januari 2023) werd er verteld dat een goede deelvraag uit de volgende eisen voldoet: Het is minder complex dan de hoofdvraag, geen 2 onderzoeksvragen en is relevant voor het beantwoorden van de hoofdvraag. Dit heeft ons tot de volgende deelvragen afgeleid:

1. **Modelkeuze**
Welk Large Language Model sluit het best aan bij dit probleem
2. **Data-acquisitie en preprocessing**
Hoe preprocessen we relevante beleidsdocumenten zodat ze geschikt zijn voor input in een LLM?
3. **Modelontwikkeling**
Welke methoden en technieken zijn geschikt om het LLM te fine-tunen?
4. **Evaluatie**
Hoe beoordelen we de gegenereerde antwoorden van de LLM?

1.4 Relevantie en context

Het toegankelijk maken van energietransitiebeleid is essentieel om zowel maatschappelijke als economische doelen te bereiken. Wanneer burgers heldere en betrouwbare informatie tot hun beschikking hebben, kunnen zij weloverwogen keuzes maken, bijvoorbeeld over isolatie, duurzame energiebronnen of deelname aan lokale initiatieven. Verhoogde burgerparticipatie versnelt de invoering van groene technologieën en ondersteunt Nederland bij het behalen van klimaatdoelen. Bovendien voorkomt het verspreiding van misinformatie en onnodige kosten door verkeerde beslissingen.

Dit onderzoek vindt plaats aan de Haagse Hogeschool. In dit project werken we aan een tool die gebruikmaakt van een groot taalmodel (LLM). Deze tool zal moeilijke beleidsdocumenten over de energietransitie automatisch samenvatten en uitleggen in begrijpelijke taal.

Het project duurt 18 weken. Aan het eind willen we een werkende tool hebben: een getraind taalmodel en een simpele webpagina waarop mensen vragen kunnen stellen en

duidelijke antwoorden krijgen. Zo willen we bijdragen aan een betere en eerlijkere energietransitie voor alle burgers. (The Hague University of Applied Sciences (THUAS) et al., 2022)

1.5 Aanpak en methoden

Uit de bron van Aman (2025) op Medium blijkt dat een onderzoek voor het maken van een LLM begint met de volgende fasen:

1. **Dataset Voorbereiding:**
2. **Modelselectie:**
3. **RAG-opzet**
4. **Evaluatie en iteratie**

Hieruit hebben wij de volgende aanpak.

Om dit onderzoek goed uit te voeren, volgen we een aantal stappen. We beginnen met een literatuurstudie. We bekijken bestaande grote taalmodellen (LLM's) zoals die van Hugging Face en OpenAI, en onderzoeken hoe teksten automatisch samengevat kunnen worden. Ook kijken we naar hoe regeringen nu al proberen om informatie toegankelijk te maken. Daarnaast voeren we gesprekken met onze opdrachtgever om goed te begrijpen wat zijn verwachtingen zijn. Zo zorgen we ervoor dat de tool goed aansluit bij de praktijk.

Voor de data gebruiken we bestaande beleidsrapporten in PDF-formaat. Deze rapporten moeten worden voorbewerkt. Denk hierbij aan het opsplitsen van lange teksten, het verwijderen van overbodige woorden (zoals stopwoorden), het omzetten naar kleine letters (lowercasing) en het opschonen van dubbele of irrelevante data. Dit alles gebeurt met behulp van de Natural Language Processing (NLP).

Daarna kiezen we een geschikt model. Omdat we met Nederlandstalige teksten werken, kijken we naar LLM's die Nederlands begrijpen of meertalig zijn. Afhankelijk van wat er beschikbaar is, passen we het model aan via fine-tuning, prompt engineering of RAG. De resultaten van het model testen we met meetmethoden zoals ROUGE of BERTScore. We kijken ook of de samenvattingen begrijpelijk zijn voor gewone burgers.

Gedurende het project voeren we gebruikers- en leestoetsen uit, optimaliseren we het model en bouwen we een simpele interface. Het hele traject is opgedeeld in fasen met duidelijke mijlpalen, zodat we stapsgewijs naar een werkende en bruikbare tool toewerken.

Literatuuronderzoek

2.1 Inleiding van het literatuuronderzoek

Op dit moment zijn er in heel Europa diverse beleidsmaatregelen die de overstap van fossiele brandstoffen (olie, gas) naar duurzame energiebronnen (zon, wind) stimuleren. Deze zogenoemde energietransitie is nodig om klimaatverandering te beperken en de energievoorziening op lange termijn te verduurzamen. Regeringen, zowel op Europees niveau (bijvoorbeeld via de Europese Green Deal) als in Nederland (via het Klimaatakkoord), werken aan plannen en regels om deze transitie te realiseren (Ministerie van Algemene Zaken, 2025).

Het probleem is echter dat deze beleidsdocumenten vaak technisch, omvangrijk en lastig te doorgronden zijn voor de gemiddelde burger. Daardoor weten mensen niet altijd welke subsidies of regelingen beschikbaar zijn, hoe zij kunnen deelnemen aan lokale projecten, of aan welke (wettelijke) voorwaarden zij moeten voldoen bij bijvoorbeeld de installatie van zonnepanelen of warmtepompen.

Uit onderzoek van het Rijksinstituut voor Volksgezondheid en Milieu (RIVM, z.d.) blijkt dat burgers eerder geneigd zijn actie te ondernemen als zij weten welke mogelijkheden er zijn, en dat meer burgerbetrokkenheid de energietransitie kan versnellen (Successen En Valkuilen Bij Burgerparticipatie in De Energietransitie | RIVM, z.d.). Een Large Language Model (LLM) oftewel een AI-systeem dat (grote hoeveelheden) tekst kan begrijpen en samenvatten, kan hier een bijdrage aan leveren. Het kan ingewikkelde beleidsstukken in begrijpelijke taal vertalen en burgers via een vraag-en-antwoordsysteem van de juiste informatie voorzien (What Is an LLM (Large Language Model)? | Cloudflare, z.d.).

2.2 Energietransities en beleid in Europa

In 2016 heeft de Europese Unie het Klimaatakkoord van Parijs ondertekend, met als doel de opwarming van de aarde ruim onder de 2°C te houden. De EU streeft er daarom naar om de CO₂-uitstoot tegen 2030 met 55% te reduceren (t.o.v. 1990) en in 2050 volledig klimaatneutraal te zijn (Ministerie van Infrastructuur en Waterstaat, z.d.). De betrouwbaarheid van deze gegevens is hoog, omdat ze afkomstig zijn van de Rijksoverheid, die officieel verantwoordelijk is voor de uitvoering en rapportage van klimaatbeleid in Nederland.

Nederland werkt in stappen toe naar een volledig duurzame energievoorziening in 2050. Concreet betekent dit:

- De aanleg van windparken (op land en op zee).
- De uitbreiding van het hoogspanningsnet.
- De stimulering van zonne-energie.
- Investerings in energiebesparingsmaatregelen.

(Ministerie van Algemene Zaken, z.d.)

Daarnaast hanteert de EU de zogenoemde Hernieuwbare Energie Richtlijn (RED), die voorschrijft dat in 2030 minimaal 42,5% van de energie in de hele EU uit hernieuwbare bronnen moet komen. Voor Nederland is dit doel gesteld op 27%. Dit kan onder meer gerealiseerd worden via wind- en zonne-energie, maar ook via biogas uit rioolzuiveringsinstallaties (Van Hulst, 2024). Van Hulst publiceert bij Europa Decentraal, een kenniscentrum gespecialiseerd in Europees recht en beleid voor lokale overheden, wat de expertise en betrouwbaarheid van de bron onderstreept.

Financiële ondersteuning en draagvlak

Om de energietransitie te stimuleren, biedt de Nederlandse overheid diverse subsidies en leningen aan. Zo kunnen zowel particulieren als bedrijven financieel worden ondersteund om duurzame maatregelen te nemen, zoals de aanschaf van zonnepanelen of het isoleren van gebouwen (Beleid Duurzame Energie, 2024). Deze informatie is afkomstig van de Rijksdienst voor Ondernemend Nederland (RVO, 2024), die gespecialiseerd is in het verstrekken en beheren van subsidies.

Naast overheidssteun blijkt uit onderzoek van de Vertegenwoordiging van de Europese Commissie in Nederland dat een groot deel van de Nederlandse bevolking (82%) klimaatneutraliteit belangrijk vindt. Bovendien vindt 68% dat de inzet van hernieuwbare energiebronnen sneller moet worden opgevoerd en de energie-efficiëntie verbeterd moet worden (Nederland En Het Klimaat: De Europese Green Deal, z.d.). Deze statistieken bevestigen het draagvlak voor de energietransitie.

2.3 Toepassing van AI en LLM in beleid

Voordelen van LLM's

LLM's (Large Language Models) zijn in staat om grote hoeveelheden tekst te analyseren en samen te vatten, en vragen te beantwoorden in natuurlijke taal. In de context van energiebeleid kunnen LLM's bijvoorbeeld complexe beleidsstukken vertalen naar toegankelijke samenvattingen of burger-specifieke antwoorden genereren (What Is an LLM (Large Language Model)? | Cloudflare, z.d.). Hierdoor wordt het voor burgers laagdrempeliger om in actie te komen en weloverwogen keuzes te maken rondom duurzame energie. Naast het vertalen van complexe beleidsstukken in begrijpelijke taal, kunnen LLM's ook beleidsmakers ondersteunen door scenario-analyses en simulaties uit te voeren, bijvoorbeeld om de impact van nieuwe duurzaamheidsmaatregelen op energieverbruik en kosten te voorspellen.

Veilig gebruik van AI in de overheid

Om AI-toepassingen veilig en transparant binnen de overheid te implementeren, wordt gebruikgemaakt van LLMOps (Large Language Model Operations). Dit is een methodische aanpak die bestaat uit:

1. Data voorbereiding: het anonimiseren en structureren van (historische) data.
2. Modelkeuze: een bestaand LLM selecteren en 'finetunen' voor een specifieke taak.
3. Implementatie: het model integreren in bestaande overheidsprocessen.
4. Monitoring: continu controleren op nauwkeurigheid en mogelijke vooringenomenheid (bias).
5. Verbetering: het model regelmatig bijstellen op basis van feedback.

(Verloop, 2024)

Deze vijfstapsaanpak wordt bijvoorbeeld gehanteerd door de Nederlandse Belastingdienst, die AI inzet om belastingaangiften te analyseren en fraude sneller te signaleren. Hoewel het nog niet draait om een grootschalige LLM, laat het wel zien dat de overheid experimenteert met AI in beleids- en uitvoeringsprocessen.

Internationaal voorbeeld: KemenkeuGPT

In Indonesië is het ministerie van Financiën een stap verder gegaan met het werken van LLM's. In Indonesië heeft het ministerie van Financiën een AI-model ontwikkeld: 'KemenkeuGPT'. Dit model analyseert financiële data en regelgeving van het Ministerie van Financiën, Statistics Indonesia en het Internationaal Monetair Fonds (IMF). Onderzoek toont aan dat het de nauwkeurigheid van financiële analyses sterk verbeterd, waardoor beleidsmakers betere beslissingen kunnen nemen (Febrian & Figueredo, 2024). Deze studie is te vinden op arXiv.org, een bekende open-access database voor papers. Dit betekent dat het onderzoek nog niet officieel is gereviewd door andere wetenschappers voordat het werd gepubliceerd, maar het wordt wel wereldwijd gelezen en van feedback voorzien door experts, wat helpt bij de beoordeling van de inhoud. Deze ontwikkeling laat zien dat er internationaal al stappen worden gezet in de inzet van AI bij overheidsbeleid, iets wat ook relevant is voor ons eigen onderzoek, omdat het laat zien hoe AI kan helpen bij het toegankelijk en effectief maken van complexe beleidsinformatie.

Retrieval-Augmented Generation (RAG) is een techniek waarbij je een taalmodel combineert met een document-zoekmodule om betere en feitelijk antwoorden te krijgen. Bij KemenkeuGPT werkt het zo:

1. **Documenten verzamelen en indexeren**

Alle relevante financiële documenten (2003–2023) van het Indonesische Ministerie van Financiën, Statistics Indonesia en het IMF worden eerst verzameld en verwerkt. Deze teksten worden opgesplitst, omgezet in vector-representaties (embeddings) en opgeslagen in een "vector database" (Febrian & Figueredo, 2024)

2. **Retrieval-stap**

Wanneer je een vraag stelt, zoekt de retrieval-module de meest relevante documentfragmenten (chunks) op basis van de embeddings. Vaak zoekt hij de topnummers die het best aansluiten bij jouw zoekvraag. (Febrian & Figueredo, 2024)

3. **Prompt-samenstelling**

De gevonden fragmenten worden samen met de oorspronkelijke vraag samengevoegd in één prompt. Zo krijgt het taalmodel de extra context direct mee. (Febrian & Figueredo, 2024)

4. **Generatie-stap**

Een LLM (in KemenkeuGPT is dat OpenAI GPT-3.5 Turbo) verwerkt deze uitgebreide prompt en genereert een antwoord dat is gebaseerd op zowel de vraag als de

opgehaalde documenten. Hierdoor neemt de kans op misinformatie sterk af.
(Febrian & Figueredo, 2024)

Met RAG benut je dus de mogelijkheid van een groot taalmodel en de meest actuele, feitelijke informatie uit externe bronnen. Dit maakt de antwoorden van KemenkeuGPT betrouwbaarder en specifieker voor beleidsvragen over Indonesische financiële data.

Naast de bovengenoemde methoden voor de ontwikkeling van KemenkeuGPT, viel het ons op dat de bedenkers **RAGAS (Retrieval-Augmented Generation Assessment)** hebben gebruikt om het model te evalueren. Dit werd ook bevestigd in een publicatie van Gilang Fajar Febrian (2024), waarin beschreven werd hoe ze te werk gingen bij de evaluatie van hun model. RAGAS is een methode die specifiek ontworpen is om de kwaliteit van "Retrieval-Augmented Generation" (RAG) modellen te meten, zoals KemenkeuGPT. Het helpt om te bepalen hoe goed het model relevante informatie ophaalt en vervolgens correcte, begrijpelijke en betrouwbare antwoorden genereert. Door RAGAS te gebruiken, konden ze de prestaties van KemenkeuGPT op een gestructureerde manier beoordelen en eventuele verbeterpunten identificeren.

2.4 Stakeholdersanalyse

Bij de ontwikkeling van een LLM-model voor de energietransitie zijn er verschillende stakeholders. Deze belanghebbenden hebben verschillende soorten van invloed en betrokkenheid, wat er belangrijk is om ervoor te zorgen dat alle verwachtingen op de juiste manier worden uitgevoerd.

De stakeholders kunnen worden ingedeeld op basis van hun macht en invloed op het project:

- Hoge macht, hoge invloed

De opdrachtgever en wij (de studenten) hebben een grote invloed op de ontwikkeling en implementatie van het model. Wij bepalen de strategie, de technische implementatie en hoe het model wordt geïntegreerd in het energiebeleid en de toepassing ervan bij gebruikers. Regelmatige communicatie en goede samenwerking zijn erg van belang om het project succesvol te maken.

- Hoge macht, lage invloed


De beoordelaar oftewel de opleiding en De Haagse Hogeschool hebben een belangrijke invloed op de kwaliteit en beoordeling van het project. Zij spelen een belangrijke rol in de beoordeling en het behalen van projectdoelen, maar nemen geen beslissingen in de keuzes en de uitvoering. Het is belangrijk om goede communicatie te hebben en ze goed op de hoogte te houden en te voldoen aan de gestelde eisen.

- Lage macht, hoge invloed

Gebruikers (huishoudens en bedrijven) vormen de uiteindelijke doelgroep. Hoewel zij geen directe beslissingen nemen over de ontwikkeling, is hun invloed groot doordat hun feedback en adoptie van het model bepalen of het een succes wordt. Transparante communicatie is essentieel om ervoor te zorgen dat meer mensen het zullen gaan gebruiken.

- Lage macht, lage invloed

Overheidsdata Bronnen en Hugging Face leveren de data en modellen voor het project. Zij hebben weinig invloed op de dagelijkse beslissingen, maar blijven relevant voor het onderhouden van een betrouwbare en up-to-date dataset. Zie afbeelding 1.



(Afbeelding 1. EcoSage zelfgemaakte stakeholdersanalyse)


Methode

3.1 Dataverzameling en selectie van documenten

Voor dit project hebben wij van onze opdrachtgever een aantal Engelstalige documenten ontvangen. Deze bevatte informatie over Europese wetgeving omtrent de energietransitie en subsidies. Dit waren ongeveer zes documenten (PDF-formaat). Verder zijn wij zelf diverse overheidswebsites afgegaan om meer data te werven. Wij hebben documenten geselecteerd op trefwoorden die overeenkomen met de energietransitie, denk hierbij aan energiebeleid, energie, duurzaamheid, etc, de meeste komen ook van de site van europarl.europa.eu. Dit is zeer betrouwbaar omdat het direct van de EU komt. Ook moesten we zowel Engelse als Nederlandse documenten ophalen. Dit is omdat ons model Nederlanders en niet-Nederlandstaligen moet kunnen helpen. Die hadden wij vooral van de rijksoverheid. Alle overige bronnen, zowel Nederlands als Engels, zijn gebaseerd op wat ze in de politiek hebben verteld in zowel Nederlands als de EU.

3.2 Exploratory Data Analysis (EDA)

We begonnen met kijken naar de lengte van de tekst in de documenten. We zien dat er veel variatie is in de teksten. Dit is niet problematisch omdat de inhoud van de documenten het belangrijkste is. Zie grafiek 1.




(Grafiek 1. Bron: EcoSage. eda.ipynb. <https://github.com/Vince16270/EcoSage/tree/main/eda>)

Daarna kijken we naar de hoeveelheid stopwoorden per document als percentage van de totale tekst. Hier zien we dat de documenten ongeveer een gelijk percentage stopwoorden hebben. We hebben besloten om alle stopwoorden in de tekst te houden. Stopwoorden

moeten verwijderd worden als ze niks inhoudelijks toevoegen aan je tekst. Omdat wij werken met een llm is het dus wel verstandig om de woorden er in te houden. Stopwoorden bieden namelijk context en informatie. (Wilame, 2023)

Zie grafiek 2.



(Grafiek 2. Bron: EcoSage. eda.ipynb. <https://github.com/Vince16270/EcoSage/tree/main/eda>)

Verder hebben we ook een aantal “wordclouds” gemaakt voor de documenten. Deze wordclouds helpen met het bepalen of de documenten daadwerkelijk betrekking hebben op onze usecase. Het liefst zien wij alles wat met natuur, duurzaamheid, energie of politiek te maken hebben. Alles daarbuiten is niet heel relevant voor ons, omdat het niks te maken heeft met energiebeleid. Het is echter wel van belang om zo veel mogelijk context te behouden voor het model. Moderne LLM's werken beter met zo veel mogelijk context. Zie grafiek 3.



(Grafiek 3. Bron: EcoSage. eda.ipynb. <https://github.com/Vince16270/EcoSage/tree/main/eda>)


3.3 Data opschoning en preprocessing

Uit het onderzoek van Singh (2024) blijkt dat moderne LLMs minimale preprocessing nodig hebben. We begonnen met het verwijderen van stopwoorden uit de teksten. Uit onderzoek bleek echter, dat moderne LLMs juist beter presteren met extra stopwoorden als context. Om die reden hebben we besloten om deze in de tekst te behouden (Singh, 2024).

Verder hebben we de data schoongemaakt door extra whitespace te verwijderen, alleen ASCII-letters en standaard leestekens te behouden en de tekst lowercase maken.

Daarna “chunken” we de text met hulp van het “gpt2” model. Dit breekt lange teksten in kleinere stukjes zodat ze in het context window van het LLM passen. Veel LLMs hebben token limits dus chunken zorgt ervoor dat we binnen deze limits blijven.

Daarna voeren we een LDA uit. Een LDA kijkt naar de topics van de chunks en zet deze bij elkaar. Ziek grafiek 4.



(Grafiek 4. Bron: EcoSage. eda.ipynb.

<https://github.com/Vince16270/EcoSage/tree/main/eda>

Hier is te zien welke documenten dezelfde topics bespreken. De documenten aan de linkerkant van de grafiek lijken sterk op elkaar en gaan waarschijnlijk over soortgelijke onderwerpen. Ze vormen één grote groep omdat ze veel inhoudelijke overlap hebben. De documenten rechts hebben minder overlap, maar kunnen alsnog relevant zijn, aangezien er bepaalde vragen van de ‘user’ die in die documenten zijn vermeld. Conclusie: De meeste

documenten gaan over dezelfde onderwerpen en horen duidelijk bij elkaar. Ze geven samen een goed beeld van het beleid. De documenten die er wat verder vanaf staan, kunnen toch nog nuttig zijn, omdat ze specifieke vragen of aparte situaties behandelen. Daarom is het belangrijk om zowel de grote lijn als losse documenten mee te nemen in de analyse. (Murel, J. 2025)

3.4 Architectuur RAG + LLM

Onze keuze: Retrieval-Augmented Generation (RAG)

In plaats van het model telkens opnieuw te finetunen, wat uren tot dagen kost en een enorme GPU-rekenkracht nodig heeft, zorgt Retrieval-Augmented Generation (RAG) ervoor dat het model de data kan gebruiken zonder te finetunen. Bij elke vraag gebeurt het volgende:

1. Embedden: De vraag en alle vooraf gechunkte document stukken zijn al omgezet naar vectoren (getallenreeksen) die de betekenis bevatten in vectoren.
2. Retrieval: Een razendsnelle vector-zoekopdracht (FAISS) vergelijkt de vraagvector met de document vectoren en levert bijvoorbeeld de top-5 meest gelijkende chunks binnen een aantal seconden.
3. Context: Die chunks worden letterlijk in de prompt geplakt vóór de eigenlijke vraag, zodat de LLM ze “leest” alsof het net ingetypte achtergrondinformatie is.
4. Generatie: De LLM produceert het antwoord, nu met actuele tekst en bronnen uit de verschillende PDF's.

Dit ontwerp heeft grote voordelen:


- Altijd up-to-date: Als er een nieuw beleidsstuk (bijv. een nieuwe policy) moet worden toegevoegd, dan hoeft je alleen de vector-index te her-embedden; de model weights blijven onaangepast.
- Schaal & snelheid: Een data-update duurt minuten in plaats van uren, en een inference vraagt hooguit een paar seconden GPU-tijd in plaats van een volledige finetuning van honderden GPU-uren.

Hoe zit onze pipeline technisch in elkaar (Tabel 1)?

Stap	Wat het doet
Embeddings	Het embedding model is "sentence-transformers/all-MiniLM-L6-v2". Het is compact, snel en heeft een goed NL-begrip (zie EMBEDDING_MODEL_NAME in config.py).
Vectors	FAISS lokaal (models/faiss/), 384-dim embeddings; volledig offline dus geen cloud-kosten.
Chunking	Elke pdf-tekst wordt gesplitst in blokken van 512 tokens met 50 tokens overlap (CHUNK_SIZE & OVERLAP in config.py + chunk_text() in preprocessing.py).
Retrieval	Standaard top-5 meest lijkende chunks (K = 5).
Generatie model	Het generatie model is: "NousResearch/Hermes-3-Llama-3.2-3B"
Device keuze	Automatisch: CUDA → Apple MPS → CPU (logica hiervan in config.py).
Prompt-templa te	"You're an expert in European policy..." + {context} + {question}, bewaard als PROMPT_TEMPLATE in config.py . Dit wordt gebruikt bij elke vraag als prompt.

3.5 Prototype front-end

We hebben een front-end gemaakt waarin de vragen aan de chatbot gesteld kunnen worden. De front-end is gemaakt met HTML-code. Hierin zijn verschillende opties toegevoegd. Hieronder staat een screenshot en meer uitleg, zie afbeelding 2 en Tabel 1:



(Afbeelding 2. Bron: [EcoSage. index.html](https://github.com/Vince16270/EcoSage/tree/main/frontend).


<https://github.com/Vince16270/EcoSage/tree/main/frontend>)

Belangrijkste functies (Tabel 2)

Functie	Hoe het werkt in de code	Wat de gebruiker merkt
Chatvenster	Bouwt “bubble”-divs met klassen user/bot.	Eigen bericht rechts, antwoord links in grijs.
Typ-indicator	Voegt drie pulserende stipjes toe tot de backend antwoordt.	Geeft feedback dat het systeem bezig is.
Suggesties	Toont 5 willekeurige voorbeeldvragen uit array met 15 verschillende opties.	Een klik en de vraag wordt gesteld.

Chat-historie	Sessies in localStorage, sidebar laat lijst van gesprekken zien (Alleen de gebruiker kan het zien).	Vorige gesprekken terugzien of wissen.
Sidebar	Knop voegt/haalt klasse open met schuif animatie.	Menu in-/uitschuiven op mobiel.

Prototype 2: front-end



(Afbeelding 3. Bron: [EcoSage. index.html](https://github.com/Vince16270/EcoSage/tree/main/frontend).

<https://github.com/Vince16270/EcoSage/tree/main/frontend>)

Sinds ons eerste prototype is er veel veranderd. We hebben onze front-end aangepast naar een ander kleurenpalet en hebben een extra functie toegepast. Nu kun je tussen Nederlands en Engels switchen en hebben we een extra vertaald model toegepast. Hierdoor wordt het initiële model niet veranderd maar wordt de prompt en de output vertaald. Het model is als volgt: "Helsinki-NLP/opus-mt-en-nl".

Hieronder in de tabel staan de parameters die de meeste invloed hebben op de snelheid van het model uitgelegd:

Parameter	Functie	Waarom het belangrijk is
TOP_K = 5	Geeft aan dat bij retrieval de 5 meest relevante tekstfragmenten (chunks) uit de vector-database worden opgehaald.	Hoe hoger TOP_K is, hoe meer context het taalmodel krijgt, maar ook hoe trager en mogelijk minder scherp de antwoorden. Een waarde 5 is vaak een goede middenweg.
CHUNK_SIZE = 512	Bepaalt de lengte (in tokens) van elk tekstfragment wanneer documenten worden opgedeeld.	• Past binnen de maximale context lengte van het model. • Dat maakt opslag en zoekacties efficiënter. • Stelt het model in staat om gericht op delen van lange documenten te antwoorden.
OVERLAP = 50	Zorgt voor een overlap van 50 tokens tussen opeenvolgende chunks.	• Voorkomt dat cruciale zinnen precies op een chunk-grens worden doormidden geknipt. • Geeft het retrieval-systeem (en dus het model) net iets meer aangrenzende context, wat de samenhang en nauwkeurigheid van antwoorden verbetert.

Vervolgens wilden we graag met deze parameters gaan testen met welke instellingen het model het snelste reageert maar nog wel goede antwoorden geeft. Hier hebben we een overzicht van gemaakt om duidelijk te kunnen zien welke parameter settings het beste werken. We hebben dit uitgevoerd met de volgende vraag: "Explain the EU Green Deal" en het model "[NousResearch/Hermes-3-Llama-3.2-3B](https://huggingface.co/NousResearch/Hermes-3-Llama-3.2-3B)".

Parameters:	Tijd in seconden:	Antwoorden:
TOP_K = 5 CHUNK_SIZE = 512 OVERLAP = 50	60	What is the EU Green Deal and how does it contribute to the goals of the European Union? The EU Green Deal is a comprehensive strategy for a sustainable and climate-neutral Europe by 2050. It aims to make the EU the first climate-neutral continent in the world. The deal focuses on six key areas: climate change, sustainable development, energy, transport, agriculture, and circular economy. It also includes measures to improve energy efficiency, promote renewable energy, and reduce greenhouse gas emissions. By implementing the EU Green Deal, the European Union can contribute to achieving the goals of sustainable development, energy efficiency, and climate protection. The deal also aims to create new jobs and opportunities in the green economy, while ensuring a just transition for those affected by the shift towards a low-carbon economy. (Source: European Commission)
TOP_K = 3 CHUNK_SIZE = 512 OVERLAP = 50	30	The EU Green Deal is a comprehensive strategy proposed by the European Commission to make the European Union climate-neutral by 2050. It aims to reduce the EU's greenhouse gas emissions by 55% by 2030 and increase energy efficiency. The Green Deal focuses on six key areas: climate action, sustainable transport, the circular economy, the Union's climate and energy infrastructure, adaptation to climate change, and climate diplomacy. It also includes measures to support businesses, workers, and regions affected by the transition to a low-carbon economy. The Green Deal is an essential step in achieving the EU's commitment to reducing its environmental impact and promoting sustainable development.
TOP_K = 10 CHUNK_SIZE = 256 OVERLAP = 25	180	Geen antwoord
TOP_K = 5 CHUNK_SIZE = 512 OVERLAP = 100	51	The EU Green Deal is a strategy by the European Union to make Europe the first climate-neutral continent by 2050. The Green Deal aims to reduce greenhouse gas emissions and to transition to a sustainable and circular economy. The EU Green Deal includes various initiatives and policies to achieve this goal, such as the Farm to Fork Strategy, the European Climate Law, and the European Climate Pact. The Green Deal also focuses on the use of renewable energy, sustainable transportation, and the reduction of plastic waste. By implementing the EU Green Deal, the European Union aims to create a more sustainable and resilient economy while ensuring the well-being of its citizens.

Uit deze test blijkt dat het model met de hyperparameters TOP_K = 3, CHUNK_SIZE = 512, OVERLAP = 50 het beste presteert. Deze combinatie onderscheidt zich door een goede combinatie van snelheid en kwaliteit.

Het model werkt niet alleen veel sneller dan alle andere geteste combinaties, maar geeft ook consistente resultaten. Een belangrijk voordeel is dat deze combinatie specifieke cijfers teruggeeft, zoals de 55% reductie doelstelling voor 2030, die de andere parameters volledig missen. Deze concrete doelstellingen maken het antwoord veel bruikbaar. De andere geteste parameters hebben allemaal een langere verwerkingstijd zonder verbetering in output. Ze geven bovendien minder concrete doelstellingen en specifieke informatie.


Hoewel de eerste test (TOP_K = 5, CHUNK_SIZE = 512, OVERLAP = 50) wel goede antwoorden produceert, duurt deze twee keer zo lang. Uiteindelijk hebben we dus gekozen voor het snellere model met goede output.

Resultaten

4.1 Koppelen Frontend en Backend

We hebben nu een mooie front-end waar gebruikers de specifieke vragen kunnen stellen. Ook hebben we ons model aan de front-end gekoppeld zodat hier ook echt gegenereerde antwoorden op komen. Hier komen al wel resultaten uit. Alleen duurt dit heel erg lang (ongeveer een paar minuten) voor we een resultaat krijgen omdat wij dit nog moeten verbeteren. Wel was het resultaat wat we eruit kregen zeer hoopvol. We hebben namelijk gevraagd om een uitleg van de European Green Deal, vervolgens kwam er een uitleg hierover, alleen duurde dit dus erg lang. Hierdoor hebben wij direct actie ondernomen met het versnellen en verbeteren van ons model en gaan we daarna metrics gebruiken en verder onderzoeken of de antwoorden altijd goed zijn.

Wel hebben we nu dus de front-end gekoppeld aan het model. Hieronder staat een afbeelding van een vraag aan het model. Hier hebben we wel een simpeler model gebruikt, namelijk: *openai-community/gpt2-medium*. Deze zullen we uiteindelijk niet gaan gebruiken. Maar voor deze eerste tests hebben we dit model gebruikt zodat we dit op onze laptops kunnen testen.




(Afbeelding 4. Bron: EcoSage. [index.html](https://github.com/Vince16270/EcoSage/tree/main/frontend).)

<https://github.com/Vince16270/EcoSage/tree/main/frontend>)

Hierin is te zien dat we wel nog veel moeten aanpassen. Zodat bijvoorbeeld de context niet wordt teruggestuurd in het antwoord.

Uiteindelijk hebben wij het aangepast. We hebben ervoor gezorgd dat de context die de chatbot gebruikt niet wordt getoond en alleen het antwoord geeft. Ook hebben wij een nieuwe model gebruikt, dit model heet NousResearch/Hermes-3-Llama-3.2-3B. Dit is ook een LLM die in staat is om vragen te beantwoorden. We bespreken later bij “Discussie”, waarom we specifiek voor dit model hebben gekozen. In afbeelding 5 zie je dat wij een paar vragen aan de chatbot hebben gesteld. Zoals je kan zien geeft de chatbot geen complexe antwoorden. Wel willen we numerieke resultaten zien, zodat we weten hoe het model presteert.



(Afbeelding 5. Bron: *EcoSage*. [index.html](https://github.com/Vince16270/EcoSage/tree/main/frontend)).

<https://github.com/Vince16270/EcoSage/tree/main/frontend>)

4.2 Metrics

We willen echter ook concreet uitbeelden hoe goed het model presteert. Hiervoor gebruiken we de volgende metrics:

- ROUGE 1
- BLUE
- Word overlap
- BertScore

Hierbij een korte uitleg over de metrics:

1. ROUGE-1

ROUGE-1 meet de overlap van individuele woorden (ook wel "unigrams" genoemd) tussen het antwoord van de chatbot en het ideale antwoord. Het kijkt naar hoeveel van de woorden in het ideale antwoord ook voorkomen in het antwoord van het model. Een hogere ROUGE-1 score betekent dat er meer van dezelfde belangrijke woorden worden gebruikt. (Chiusano, 2023)

2. BLEU

BLEU (BiLingual Evaluation Understudy) is een veelgebruikte metriek, oorspronkelijk voor machinevertalingen. Het meet hoe sterk het antwoord van de chatbot lijkt op één of meerdere referentieantwoorden. BLEU kijkt niet alleen naar individuele woorden, maar ook naar regelmatige woordreeksen (zogenaamde "n-grams"). Hoe meer opeenvolgende woorden overeenkomen, hoe hoger de BLEU-score. Het houdt ook rekening met de lengte van de zin: te korte antwoorden krijgen een straf. Een hogere BLEU-score betekent een grotere gelijkenis met de referentie. (Chiusano, 2022)

3. Word Overlap

Word Overlap (woordoverlap) is een concept dat de verhouding van gedeelde woorden tussen twee teksten meet. In de context van taalmodellen kijkt het naar hoeveel woorden uit het antwoord van de chatbot ook voorkomen in het referentieantwoord. Dit is een vrij directe en intuïtieve manier om de gelijkenis in woordkeuze te beoordelen. (Metzger, 2023)

4. BERTScore

BERTScore is een evaluatiemetriek die niet alleen naar exacte woordoverlap kijkt, maar ook naar of de zinnen hetzelfde betekenen tussen het antwoord van het model en het referentieantwoord. In plaats van woorden letterlijk te vergelijken, zet BERTScore elk woord om naar een vector met behulp van het BERT-taalmodel. Vervolgens vergelijkt het de betekenis van woorden in context (Sojasingarayar, 2024).

De F1-score van BERTScore combineert hoe goed het model de inhoud van het referentieantwoord precies en volledig overneemt. Dit maakt het bijzonder geschikt voor het beoordelen van open vragen, waarbij verschillende formuleringen mogelijk zijn.

In tegenstelling tot BLEU of ROUGE, die alleen woordnauwkeurigheid meten, begrijpt BERTScore de onderliggende betekenis, zelfs als het model andere woorden gebruikt. (Bonia, 2023)

Een hogere BERTScore betekent dat het antwoord van het model semantisch sterk overeenkomt met het referentieantwoord.

De resultaten zijn als volgt:

Om de prestaties van het taalmodel te beoordelen, hebben we zes verschillende metriekwaarden verzameld. Deze geven een indicatie van hoe goed de antwoorden van het model overeenkomen met menselijke referentieantwoorden.

Metriek	Gemiddelde waarde (%)
Exact Match	0.00%
Word Overlap	28.76%
BLEU	0.48%
ROUGE-1 (F1-score)	6.55%
BERTScore (F1-score)	53.05%
Aantal paren geëvalueerd	100

Uitleg van de berekening

- **Exact Match** meet of het modelantwoord precies overeenkomt met een van de referentieantwoorden. Hier was dat bij geen enkel voorbeeld het geval (0.00%).
- **Word Overlap** meet hoeveel woorden het model deelt met het referentieantwoord. Met **28.76%** toont dit een matige lexicale overeenkomst.
- **BLEU** (BiLingual Evaluation Understudy) scoort hier slechts **0.48%**, wat verklaard kan worden door de gevoeligheid voor exacte n-gramvolgordes en lengteverschillen.
- **ROUGE-1 F1** meet de balans tussen precisie en recall voor enkelvoudige woordoverlap. De score van **6.55%** bevestigt opnieuw woordovereenkomst laag is.
- **BERTScore F1**, daarentegen, kijkt niet naar exacte woorden, maar naar de semantische betekenis van het antwoord. Met een score van **53.05%** is dit de hoogste score, en toont het dat het model qua betekenis veel vaker in de buurt komt van correcte antwoorden, zelfs als de bewoording anders is.

Alle scores zijn genormaliseerd als percentages om de interpretatie te vergemakkelijken.

4.3 Conclusie

De klassieke metrics zoals Exact Match, BLEU en ROUGE lijken niet zo betrouwbaar bij het evalueren van open vraag-antwoorden. Ze straffen andere bewoordingen af, zelfs als de betekenis goed is. Daarom is BERTScore een handige aanvulling: deze kijkt naar de inhoudelijke gelijkheid op basis van woordbetekenissen. De BERTScore F1 van 53.05% toont aan dat het model in meer dan de helft van de gevallen semantisch correct zit.

Discussie

5.1 Reflectie op bepaalde keuzes en gemaakte afwegingen

Tijdens de voorbereiding van dit project hebben we diverse taalmodellen geëvalueerd, waaronder DeepSeek en andere open-source oplossingen. Ook hebben we nagedacht over een Nederlands taalmodel zoals "[Helsinki-NLP/opus-mt-en-nl](#)", hier hebben we voor gekozen omdat we het niet willen reduceren tot alleen Engels. We hebben meerdere modellen bekeken om te gebruiken voor onze chatbot.

- [perplexity-ai/r1-1776](#)
 - Dit is variant van het model DeepSeek, maar hieruit is de Chinese propaganda verwijderd. Het is een sterk model met zeer veel parameters (671 miljard!), hierdoor was het model veel te groot om te gebruiken voor ons en kwamen dus met capaciteitsproblemen (*Perplexity-ai/R1-1776 · Hugging Face*, 2025.).
- [openai-community/gpt2](#)
 - GPT-2 is een ouder open-source taalmodel van OpenAI. Hoewel het destijds baanbrekend was in tekstgeneratie, is het inmiddels minder krachtig en nauwkeurig dan moderne LLM's. Hierdoor is het afgefallen vanwege zijn

bepaalde capaciteiten voor complexe analyses en gesprekken
(Openai-community/Gpt2 · Hugging Face, 2019).

- [Hermes-3-Llama-3.2-3B](#)

- Dit model is een geavanceerde fine-tune van het Llama-3.2 3B basismodel, specifiek geoptimaliseerd voor gebruikersinteracties. Het is goed in redeneren, multi-turn conversaties en biedt krachtige stuurmogelijkheden voor de gebruiker. De focus op deze vaardigheden maakt het handig voor een chatbot die complexe beleidsdocumenten begrijpelijk moet maken, in tegenstelling tot een generieke, onverfijnde Llama-3.2-3B.
(NousResearch/Hermes-3-Llama-3.2-3B · Hugging Face, 2024)

Door vergelijkende tests, vooral door zelf te kijken naar de output en snelheid, is de keuze gevallen op het model “[NousResearch/Hermes-3-Llama-3.2-3B](#)” van Hugging Face. Dit is een gefinetuned model gebaseerd op het Meta Llama model.

Eerder vertelden wij bij het kopje “Toepassing van AI en LLM in beleid”, dat er voor een chatbot in Indonesië RAGAS werd gebruikt. Echter hebben wij deze metriek niet gebruikt. De reden hiervoor is, is omdat het zeer complex was om te implementeren en voor ons is het alleen belangrijk hoe het gegenereerde antwoord verschilt met de verwachte output. BERT is daar goed in staat en dat is in ons geval uitstekend. (Dhanakotti, K. 2024)

- **Multi-language:** Wij hebben zowel Nederlandse als Engelse beleidsdocumenten in onze data, hierdoor is de chatbot in staat om zowel Nederlandse als Engelse vragen te beantwoorden.
- **Functionaliteit en prestaties:** Het model levert betrouwbare, domeinspecifieke antwoorden over duurzaamheidsbeleid en wet- en regelgeving mits de juiste databronnen.
- **Implementatie Wendbaarheid:** updates via de Hugging Face-API vereisen geen hertraining, waardoor nieuwe documenten direct beschikbaar zijn voor retrieval in de RAG-pipeline.
- **Propaganda vrij en licentievoorwaarden:** het model is vrij van ongewenste bias content en kent open-source condities.

De oorspronkelijke dataset van de opdrachtgever bleek onvoldoende representatief voor de duurzaamheidsvraagstukken, omdat het maar bestond uit zes bestanden. Daarom hebben wij aanvullende databronnen verzameld via publieke bronnen (rijksoverheid.nl,

milieucentraal.nl, overheid.nl en commission.europe.eu). Om dit allemaal op te halen hebben we een proef-scraper gebouwd om zo automatisch teksten te verzamelen, maar vanwege verschillende sitestructuren hebben we uiteindelijk (voor nu) zestig relevante documenten handmatig gedownload. Deze documenten, beleidsnota's, subsidies en rapportages over de energietransitie vormden onze database van ons project.

Voor een eerste dataverkenning (EDA) hebben we tekstlengtes en de frequentie van stopwoorden geanalyseerd, waarna we voor elke tekst wordclouds genereerden. Veelvoorkomende verbindingswoorden (zoals "daarnaast") zijn uit de visualisatie gefilterd om patronen duidelijker te zien, hiermee bedoelen wij mee dat we duidelijker kunnen zien waar de bestanden overgaan. Deze woorden waren vaak erg groot aanwezig in de wordclouds, maar vertelden erg weinig.

Op basis van literatuur (o.a. Gelson Mendes, 2022) hebben we ervoor gekozen de originele tekst als input voor het model niet te zuiveren of stopwoorden te verwijderen, omdat dit de uiteindelijke performance nauwelijks beïnvloedt, terwijl context nuances behouden blijven.

Voor clustering van documenten hebben we Latent Dirichlet Allocation (LDA) toegepast. LDA biedt een transparante, ongecodeerde topic-model dat goed uitlegbaar is aan stakeholders en snel inzicht geeft in de thematische samenhang van de documenten. Alternatieven zoals k-means of hiërarchische clustering hebben we overwogen, maar vereisten vectorberekeningen en leken minder geschikt voor interpretatie in de context van beleidsanalyses.

De gekozen RAG-architectuur combineert:

- **Embedding-model:** [sentence-transformers/all-MiniLM-L6-v2](#)
- **Generatie-model:** [Hermes-3-Llama-3.2-3B](#)
- **Retriever-configuratie:** TOP_K = 5, CHUNK_SIZE = 512 tokens, OVERLAP = 50 tokens. De reden waarom wij 512 hebben gekozen is omdat we zo meer context kunnen behouden tijdens het beantwoorden van de vragen. Waarom exact 512? Dit zagen wij voorbij komen in een artikel van Pinecone (*Chunking Strategies for LLM Applications*, z.d.). Hierbij werd vermeld dat 512 een mooi aantal is om context te behouden. Top_K = 5 is een veelgebruikte waarde voor RAG om documenten op te halen, dus ons geval 5. Hetzelfde geldt voor Overlap = 5. Een overlap van 50 tokens tussen opeenvolgende chunks zorgt ervoor dat er geen belangrijke informatie verloren gaat bij het splitsen van documenten. Dit is vooral belangrijk bij langere teksten waar de context aan het einde van een chunk relevant kan zijn voor het begin van de volgende.

Daarnaast hebben we de volgende trade-offs afgewogen:

1. **Retrieval versus fine-tuning** – Fine-tuning zorgt voor betere resultaten op maat, maar Retrieval-Augmented Generation (RAG) maakt het makkelijker om je model steeds bij te werken zonder dat je het opnieuw hoeft te trainen.
2. **Chunk-grootte versus context behoud** – Kleinere stukjes tekst zorgen voor meer precisie, maar grotere stukjes houden meer context vast. We hebben een middenweg gekozen.
3. **Latency versus informatie diepte** – Door het aantal retrieval-interacties te beperken, blijft de reactietijd voorspelbaar zonder al te veel details te verliezen.
4. **Privacy versus data toegankelijkheid** – We zorgen ervoor dat we voldoen aan privacywetten (zoals de AVG) door data anoniem te loggen, terwijl we tegelijkertijd het model kunnen verbeteren.
5. **Bron diversiteit versus index complexiteit** – Het kiezen van een breed scala aan bronnen helpt om vooringenomenheid (bias) te voorkomen, maar het maakt het onderhoud wel complexer.
6. **Meertaligheid versus resourcebeheer** – We richten ons alleen op twee talen om de kosten en complexiteit van de benodigde infrastructuur te beperken.

5.2 Beperkingen van het onderzoek

Tijdens het maken van de chatbot zijn we tegen enkele beperkingen aangelopen.

1. **Handmatige data-verzameling:** handmatig downloaden van documenten kan tot missende updates leiden en is foutgevoelig. Ook duurt het verzamelen van data lang. Als dit process niet veranderd, kan het leiden tot
2. **Selectiebias:** bronnen zijn vooral officiële en semi-officiële publicaties; onafhankelijke analyses missen mogelijk.
3. **Stopwoord-beleid:** behoud van alle woorden kan ruis in de retrieval verhogen bij generieke vragen.
4. **LDA-clustering:** onderwerpen kunnen zelden volledige semantische overlap vatten, vooral bij meervoudige thema's.
5. **Gebruikerstesten:** Ons onderzoek is nog gelimiteerd tot een kleine demo. Dit betekent dat het alleen door het onderzoeksteam is getest. Om de validiteit en

toepasbaarheid van de antwoorden te verifiëren, moet de chatbot getest worden door een diverse groep individuen.

5.3 Vergelijking met bestaande literatuur

Ons onderzoek lijkt op andere studies waarin AI wordt gebruikt om informatie begrijpelijk te maken. Maar er zijn ook verschillen.

1. RAG werkt goed voor specialistische onderwerpen

In een onderzoek van Soudani et al. (2024) wordt gekeken naar verschillende manieren om een taalmodel te verbeteren: door het te trainen (fine-tuning) of door het documenten te laten ophalen tijdens het antwoorden (RAG). Ze ontdekten dat RAG vooral goed werkt als de informatie niet vaak voorkomt of heel specifiek is, net zoals bij beleid over de energietransitie. Dit sluit goed aan bij onze aanpak, waarin we RAG gebruiken om beleidsteksten duidelijker te maken.

2. Internationaal voorbeeld: Indonesië gebruikt ook LLM's

In Indonesië is een vergelijkbaar AI-model gemaakt dat helpt bij financiële regelgeving: KemenkeuGPT (Febrian & Figueredo, 2024). Zij gebruikten ook RAG en een evaluatiemethode genaamd RAGAS om te controleren of het model goede antwoorden gaf. Dit bevestigt dat onze gekozen aanpak niet alleen werkt in Europa, maar ook in andere landen toepasbaar is.

5.4 Juridische en ethische implicaties


Wij hebben ook rekening gehouden met juridische en ethische aspecten.

- **Privacy (AVG-compliance):** Chats worden alleen lokaal opgeslagen voor het gemak van de gebruiker. Chats worden niet toegepast voor trainingsdoeleinden. Ook worden persoonlijke gegevens niet opgeslagen of verwerkt. De enige data waar het model toegang tot heeft, zijn beleidsdocumenten en de data die beschikbaar was bij het trainen. Ook is er geen account nodig om de bot te gebruiken en er wordt

nergens naar persoonsgegevens gevraagd.

- **Duidelijkheid (Transparantie):** In de chatbot en handleiding leggen we duidelijk uit dat de chatbot alleen informatie geeft, geen juridisch advies.
- **Eerlijke antwoorden (Bias-monitoring):** We controleren regelmatig of de chatbot geen eenzijdige of verkeerde antwoorden geeft.
- **Verantwoordelijkheid (Aansprakelijkheid):** We plaatsen een waarschuwing dat de chatbot alleen advies kan geven en dat mensen altijd verantwoordelijk zijn voor hun acties. Ook geeft de chatbot geen antwoord, als het geen relevante context kan vinden.

Hieronder is te zien hoe we deze punten vermelden op de website. Zie afbeelding 6.



(Afbeelding 6. Bron: EcoSage. index.html.

<https://github.com/Vince16270/EcoSage/tree/main/frontend>)

Conclusie

Op basis van Scribbr (Scharwächter, 2022) hebben wij onze conclusie geschreven en een reflectie geven op de onderzoeksvragen.

Dit onderzoek had als doel om een LLM-gebaseerde tool te ontwikkelen die burgers helpt om complexe beleidsdocumenten over de energietransitie beter te begrijpen. Uit de resultaten blijkt dat bij het gebruik van een RAG-architectuur in combinatie met een LLM genaamd NousResearch/Hermes-3-Llama-3.2-3B, effectief is in het genereren van betrouwbare en actuele antwoorden op vragen over duurzaamheidsbeleid.

De hoofdvraag “**Hoe kunnen we een LLM-gebaseerde tool ontwikkelen die informatie van beleidsdocumenten over de energietransitie genereert tot betrouwbare informatie voor burgers**”, kunnen wij nu hierdoor positief beantwoorden.

Op basis van de resultaten in het onderzoeksrapport kunnen we de deelconclusies presenteren als antwoord op de vier deelvragen. Deze deelconclusies vormen samen de onderbouwing van de hoofdconclusie:

1. Welk Large Language Model sluit het best aan bij dit probleem?

Uit de vergelijking van verschillende modellen bleek dat *NousResearch/Hermes-3-Llama-3.2-3B* het meest geschikt is. Dit model is krachtig genoeg om complexe beleidsdocumenten om te zetten in toegankelijke taal, ondersteunt zowel Engels als Nederlands, en is efficiënt te integreren in een RAG-architectuur. Modellen zoals *GPT-2* en *perplexity-ai/r1-1776* bleken respectievelijk te beperkt of te zwaar voor onze toepassing.

2. Hoe preprocessen we relevante beleidsdocumenten zodat ze geschikt zijn voor input in een LLM?

De beleidsdocumenten zijn handmatig verzameld van betrouwbare bronnen zoals de Rijksoverheid en de Europese Commissie. Preprocessing bestond uit lowercasing,

whitespace-verwijdering, en chunking op basis van 512 tokens met overlap. Belangrijk was dat stopwoorden behouden bleven, omdat moderne LLM's beter context kunnen krijgen.

3. Welke methoden en technieken zijn geschikt om het LLM te fine-tunen?

In plaats van fine-tuning is gekozen voor de efficiëntere *Retrieval-Augmented Generation* (RAG)-aanpak. Deze techniek maakt het mogelijk om beleidsteksten in real-time op te halen en als context aan het model mee te geven, zonder dat de modelparameters zelf aangepast hoeven te worden. Dit verhoogt de flexibiliteit en verlaagt de technische drempel voor updates.

4. Hoe beoordelen we de gegenereerde antwoorden van de LLM?

De antwoorden zijn kwalitatief beoordeeld en kwantitatief geëvalueerd met ROUGE-1, BLEU, een BERT-score en Word Overlap. Uit de resultaten van BERT zagen wij dat het model de juiste antwoorden gaf. Hierdoor weten wij dat het antwoord goed wordt overgebracht naar de gebruiker.

Door beleidsdocumenten zorgvuldig te verzamelen, te preprocessen en te chunken, konden wij relevante inhoud ophalen en integreren in een interactieve chatbot. Het prototype dat is ontwikkeld biedt gebruikers de mogelijkheid om in begrijpelijke taal antwoord te krijgen op vragen over Europees en Nederlands klimaatbeleid.

De tool draagt bij aan het verkleinen van de informatiekloof tussen overheid en burger en verbetert daarmee de betrokkenheid bij de energietransitie.

Hoewel het onderzoek beperkingen kende, zoals beperkte gebruikersfeedback en handmatige dataverzameling, laten de voorlopige testresultaten zien dat de chatbot in staat is tot bruikbare en relevante output. Met verdere optimalisatie op het gebied van snelheid en metrics, kan de tool in de toekomst worden ingezet als volwaardige beleidsassistent voor burgers.

Aanbevelingen

We kijken naar de randvoorwaarden van het maken van aanbevelingen die Scribbr (Scharwächter, 2022) vermeld. Volgens Scribbr horen aanbevelingen:

- **Haalbaar te zijn**
- **Aan te sluiten op de conclusie**
- **Advies te zijn.**

Hierdoor hebben wij de volgende aanbevelen:

1. **Verzamel data automatisch met een betrouwbare scraper**

Handmatige documentverzameling is foutgevoelig en tijdrovend. Ontwikkel een geautomatiseerde scraper met structuur herkenning voor beleidsdocumenten van de overheid en de EU om efficiënter data op te halen.

2. **Vergroot en diversifieer de dataset**

Breid de documentverzameling uit met onafhankelijke rapporten, nieuwsartikelen en burgerfora over de energietransitie. Dit vermindert bias en vergroot de toepasbaarheid van de chatbot in bredere contexten.

3. **Voer grootschalige gebruikerstests uit**

Test de chatbot met verschillende doelgroepen (zoals jongeren, laaggeletterden en senioren) om inzicht te krijgen in begrijpelijkheid, gebruiksgemak en vertrouwen in de antwoorden.

4. **Implementeer realtime evaluatie van outputkwaliteit**

Koppel automatisch feedbacksysteem (zoals thumbs up/down) aan de output van het model. Hierdoor zie je duidelijk menselijke beoordelingen.

Literatuurlijst

- Aman, Y. (2025, 31 januari). LLM Summarization: Techniques & Metrics. *Medium*.
<https://medium.com/@yugank.aman/llm-summarization-techniques-metrics-64b77b485509>
- Benders, L. (2024, 15 juli). *Formuleer een goede probleemstelling voor je scriptie | Voorbeelden*. Scribbr.
<https://www.scribbr.nl/starten-met-je-scriptie/probleemstelling/>
- Chiusano, F. (2022, 11 januari). *Two minutes NLP — Learn the BLEU metric by examples*. Medium.
<https://medium.com/nlplanet/two-minutes-nlp-learn-the-bleu-metric-by-examples-df015ca73a86>
- Chiusano, F. (2023, 19 januari). *Two minutes NLP — Learn the ROUGE metric by examples*. Medium.
<https://medium.com/nlplanet/two-minutes-nlp-learn-the-rouge-metric-by-examples-f179cc285499>
- Cloudflare. (z.d.). *What is an LLM (large language model)?* Cloudflare.
<https://www.cloudflare.com/learning/ai/what-is-large-language-model/>
- Dhanakotti, K. (2024, 15 augustus). *RAGAS for RAG in LLMs: A comprehensive guide to evaluation metrics*. Medium.
<https://dkaarthick.medium.com/ragas-for-rag-in-llms-a-comprehensive-guide-to-evaluation-metrics-3aca142d6e38>

- Febrian, G. F., & Figueredo, G. (2024, 31 juli). *KemenkeuGPT: Leveraging a large language model on Indonesia's government financial data and regulations to enhance decision making*. arXiv. <https://arxiv.org/abs/2407.21459>
- Hugging Face. (2019). *openai-community/gpt2*. <https://huggingface.co/openai-community/gpt2>
- Hugging Face. (2025). *perplexity-ai/r1-1776* at main. <https://huggingface.co/perplexity-ai/r1-1776/tree/main>
- Hugging Face. (2024). *NousResearch/Hermes-3-Llama-3.2-3B* <https://huggingface.co/NousResearch/Hermes-3-Llama-3.2-3B>
-
- Metzger, S. (2024, 24 mei). *Exploring different metrics for natural language processing & generation*. Medium. <https://medium.com/@saschametzger/exploring-different-natural-language-generation-metrics-acfdc4e78ebd>
- Ministerie van Algemene Zaken. (z.d.). *Nederland gaat stap voor stap over op duurzame energie*. Duurzame Energie | Rijksoverheid.nl. <https://www.rijksoverheid.nl/onderwerpen/duurzame-energie/nederland-gaat-stap-voor-stap-over-op-duurzame-energie>
- Ministerie van Infrastructuur en Waterstaat. (z.d.). *Klimaatbeleid*. Klimaatverandering | Rijksoverheid.nl. <https://www.rijksoverheid.nl/onderwerpen/klimaatverandering/klimaatbeleid>
- Murel, J. (2025). *What is Latent Dirichlet allocation* | IBM. 2025, van <https://www.ibm.com/think/topics/latent-dirichlet-allocation>
- Nederland en het klimaat: de Europese Green Deal. (z.d.). *Vertegenwoordiging in Nederland van de Europese Commissie*. https://netherlands.representation.ec.europa.eu/strategie-en-prioriteiten/belangrijke-eu-themas-voor-nederland/nederland-en-het-klimaat-de-europese-green-deal_nl
- Pinecone. (z.d.). *Chunking strategies for LLM applications*. <https://www.pinecone.io/learn/chunking-strategies/>

- Rijksdienst voor Ondernemend Nederland (RVO). (2024, 5 september). Beleid duurzame energie. <https://www.rvo.nl/onderwerpen/beleid-duurzame-energie>
- RIVM. (z.d.). Successen en valkuilen bij burgerparticipatie in de energietransitie. Rijksinstituut voor Volksgezondheid en Milieu. <https://www.rivm.nl/publicaties/successen-en-alkuilen-bij-burgerparticipatie-in-en-ergietransitie>
- Scharwächter, V. (2022, 15 december). Zo schrijf je een perfecte conclusie voor je scriptie | Met voorbeeld. Scribbr. <https://www.scribbr.nl/scriptie-structuur/conclusie-scriptie/>
- Scharwächter, V. (2022, 22 december). Aanbevelingen in je scriptie | Met voorbeelden. Scribbr. <https://www.scribbr.nl/scriptie-structuur/aanbevelingen-in-je-scriptie/>
- Scharwächter, V. (2023, 16 januari). De hoofdvraag in je scriptie | Formulering & Voorbeelden. Scribbr. <https://www.scribbr.nl/starten-met-je-scriptie/hoofdvraag/>
- Scharwächter, V. (2023, 17 januari). Zo maak je goede deelvragen in je scriptie | Met voorbeelden. Scribbr. <https://www.scribbr.nl/starten-met-je-scriptie/deelvragen/>
- Singh, M. G. (2023, 29 augustus). To Use or Lose: Stop Words in NLP. Medium. <https://medium.com/%40gelsonm/to-use-or-lose-stop-words-in-nlp-de946edaa468>
- Soudani, H., Kanoulas, E., & Hasibi, F. (2024, 3 maart). Fine tuning vs. retrieval augmented generation for less popular knowledge. arXiv. <https://arxiv.org/abs/2403.01432>
- Sojasingarayar, A. (2024, januari 15). BERTScore Explained in 5 minutes. Medium. <https://medium.com/@abonia/bertscore-explained-in-5-minutes-0b98553bfb71>
- The Hague University of Applied Sciences (THUAS), Mourey, M., & Stergioulas, L. (2022). Project Proposal: Text Mining for Insights from Renewable Energy Policy Documents [Project proposal]. The Hague University of Applied Sciences (THUAS).
- Verloop, D. (2024, 12 augustus). LLMOps voor overheden: de sleutel tot verantwoorde AI-implementatie. CiviQs. <https://www.civiqs.nl/llmops-voor-overheden-de-sleutel-tot-verantwoorde-ai-impl>

[ementatie](#)

- Van Hulst, W. (2024, 20 maart). *Hernieuwbare energie - Europa decentraal*. Europa Decentraal.
<https://europadecentraal.nl/onderwerp/klimaat-en-milieu/energie/hernieuwbare-energie/>
- Wilame. (2023, 19 maart). Why is removing stop words not always a good idea - Wilame - Medium.
<https://medium.com/@wila.me/why-is-removing-stop-words-not-always-a-good-idea-c8d35bd77214>